



Modelisation linéair

Diagnostic de régression : TEST: Prime linéaire (LogReg + GammaReg)

Diagnostic de régression : Gamma Regression



Diagnostic classification : Logistic Regression



Avantages :

- + Facilement interpretable
- + Facile à Optimiser (HPO)
- + Rapide


Inconvénients :

- Moins performant
- comprends moins bien les relations


Modelisation ensembliste (arbres)

Diagnostic de régression : TEST: Prime ensemble (RF + XGB)

Diagnostic de régression : XGBoost regression



Diagnostic classification : Random Forest Classification



Avantages :

- + Plus performant
- + Encore largement optimisable
- + Rapide

Inconvénients :

- « boîte noire » mais explicable
- hyperparametrage important

Conclusion

Typologie de modèle

J'ai choisi d'améliorer le modèle sinistre*severité (2), étant donné une baseline fonctionnelle, et des premiers tests concluants.

data processing

Le jeu de donnée d'entrée était plutôt propre et peu de processing a été effectué, hormis l'encodage et typage des variables.

Les pipelines scikitlearn sont intéressants mais piégeux et finalement peu utiles si l'on veut vraiment maîtriser son code (surtout avec des process customisés). Il est embêtant lors d'un .fit() de réentraîner le préprocesseur quand celui-ci est sensé être immuable.

->Améliorations possibles :

- On pourra cependant l'améliorer avec de l'over/under sampling, prévu pour rééquilibrer les variables à expliquer Y.
- D'autres approches de scaling (min-max) et d'imputation (knn) auraient pu être envisagées, mais celles indiquées étaient déjà suffisantes.
- Avec une meilleure connaissance du métier, un meilleur feature engineering aurait pu être envisagé.

performances du model

Comme on peut s'y attendre le pipeline de modèle ensembliste est meilleur que son voisin linéaire, cependant sa haute sophistication "boîte noire" devient problématique pour sa bonne maîtrise/compréhension notamment pour s'assurer des déviations ou effets de bord du modèle pour la mise en production.

->Améliorations possibles :

- On pourra cependant l'améliorer le paramétrage des hyperparamètres, (HPO) avec plus de temps et l'utilisation de Grid/RandomSearch. Certains paramètres sont ajustables à la main et dépendent du contexte de données, certains sont nécessairement à ajuster à l'aide d'expériences.
- On pourrait envisager d'autres types de modèles, comme les SVM, ou réseau de neurones ou autres.. mes nombreux tests n'ont pas montré quelque chose de satisfaisant.. (l'hyperparamétrage est sensible)